

POREĐENJE FLOWSOM ALGORITMA I STANDARDNIH ALGORITAMA KLAUSTEROVANJA

Seminarski rad iz predmeta
„Istraživanje podataka 2“,
Matematički fakultet, Univerzitet u
Beogradu, 06.02.2026.

Profesor: Mirjana Maljković Ružičić

Jovan Ranković 62/2021 Filip Dramićanin 303/2023

Sadržaj

1. Uvod	4
2. Opis zadatka	6
3. Podaci.....	8
3.1. Izvor i kontekst	8
3.2. Struktura	8
3.3. Opis atributa.....	9
3.4. Atribut koncentracije gasa.....	9
3.5. Ciljni atribut Class	10
4. Pretprocesiranje.....	11
4.1. Učitavanje i inicijalno čišćenje podataka.....	11
4.2. Analiza nedostajućih vrednosti.....	12
4.3. Obrada Outliera (Ekstremnih vrednosti).....	12
4.4. Skaliranje	13
4.5. Formiranje pretprocesiranog skupa podataka	13
5. Redukcija (PCA, Feature Selection)	14
5.1. Feature Selection.....	14
5.1.1. Eliminacija atributa sa malom varijansom	14
5.1.2. Eliminacija visoko korelisanih atributa.....	15
5.1.3. Vizuelizacija korelacije nakon primene FS.....	15
5.2. PCA.....	16
5.2.1. Izbor broja komponenti na osnovu objašnjene varijanse	16
5.2.2. Transformacija podataka u PCA prostor	17
5.2.3. Vizuelizacija PCA objašnjene varijanse	17
5.3. Poređenje FS i PCA metoda	18
6. Algoritmi Klasterovanja	19
6.1. KMeans	19
6.1.1. Opis algoritma	19
6.1.2. Izbor broja klastera	20
6.1.3. Implementacija	20

6.2.	GMM – Gaussian Mixture Model	21
6.2.1.	Opis algoritma	21
6.2.2.	Određivanje broja komponenti	21
6.2.3.	Implementacija	21
6.3.	DBSCAN.....	22
6.3.1.	Opis algoritma	22
6.3.2.	Izbor parametara i implementacija	22
6.4.	HDBSCAN.....	23
6.4.1.	Opis algoritma	23
6.4.2.	Prednosti	24
6.4.3.	Implementacija i parametri.....	24
6.5.	FlowSOM	25
6.5.1.	Opis algoritma	25
6.5.2.	Uloga FlowSOM algoritma.....	25
6.5.3.	Implementacija i izbor parametara	25
7.	Analiza dobijenih rezultata	27
7.1.	KMeans	27
7.1.1.	Numeričke metrike evaluacije	27
7.1.2.	tSNE/UMAP vizuelizacije.....	28
7.1.3.	Analiza klastera.....	28
7.1.4.	Rezime.....	29
7.2.	GMM	29
7.2.1.	Numeričke metrike evaluacije	29
7.2.2.	tSNE/UMAP vizuelizacije.....	31
7.2.3.	Analiza klastera.....	31
7.2.4.	Rezime.....	32
7.3.	DBSCAN.....	33
7.3.1.	Numeričke metrike evaluacije	33
7.3.2.	tSNE/UMAP vizuelizacije.....	34
7.3.3.	Analiza klastera.....	34

7.3.4.	Rezime.....	35
7.4.	HDBSCAN	36
7.4.1.	Numeričke metrike evaluacije	36
7.4.2.	tSNE/UMAP vizuelizacije.....	37
7.4.3.	Analiza klastera.....	37
7.4.4.	Rezime.....	38
7.5.	FlowSOM	39
7.5.1.	Numeričke metrike evaluacije	39
7.5.2.	tSNE/UMAP vizuelizacije.....	40
7.5.3.	Analiza klastera.....	40
7.5.4.	Rezime.....	41
8.	Zaključak.....	42
9.	Literatura	44

1. Uvod

Cilj ovog projekta je detaljna analiza i poređenje FlowSOM algoritma sa standardnim algoritmima klasterovanja na realnom visokodimenzionalnom skupu podataka koji sadrži merenja gasnih senzora pri različitim koncentracijama.

Standardni algoritmi klasterovanja, kao što su KMeans, HDBSCAN, DBSCAN i GMM široko su zastupljeni u praksi zbog svoje jednostavnosti i dobre interpretabilnosti. Međutim, ovi algoritmi imaju određena ograničenja, naročito kada se primenjuju na skupove podataka sa velikim brojem atributa, prisutnim šumom, velikim brojem instanci itd. Problemi poput potrebe za unapred zadatim brojem klastera ili slabe skalabilnosti mogu značajno uticati na kvalitet dobijenih rešenja.

Nasuprot standardno korišćenim algoritmima, FlowSOM algoritam zasnovan na neuronskim mrežama i samoorganizujućim mapama predstavlja alternativan pristup klasterovanju. FlowSOM je algoritam koji kombinuje samoorganizujuće mape (SOM – Self-Organizing Maps) sa dodatnim koracima metaklasterovanja, čime omogućava efikasno grupisanje podataka u nižedimenzionalnom prostoru uz očuvanje topoloških odnosa između instanci. Prvobitno je razvijen za analizu podataka iz protočne citometrije, ali je pronašao primenu i u drugim oblastima gde se radi sa visokodimenzionalnim numeričkim podacima.

Radi fer i korektnog poređenja navedenih algoritama, svakom od njih su dostavljenje iste 3 verzije originalnog skupa podataka (Potpun pretprocesiran, feature selection redukovan, i pca redukovan skup), tj. verzije koje su pre primene algoritama nad njima na potpuno isti način izmenjene (Pretprocesiranjem i redukcijom koje će u narednim poglavljima biti detaljnije objašnjene). Nakon toga, izvršene su vizuelizacije i primenjene različite metrike radi evaluacije modela i njihovog upoređivanja tj. upoređivanja rezultata njihove primene.

Kao dodatna motivacija za ovakvo istraživanje nametnuo se jako zanimljiv fenomen koji predstavlja veliki i značajan izazov u radu sa realnim senzorskim podacima a to je fenomen drifta, odnosno promene karakteristika senzora tokom vremena. Drift može dovesti do pogoršanja performansi klasičnih modela i otežati interpretaciju rezultata klasterovanja. Zbog toga je zanimljivo a i jako bitno ispitati kako se različiti algoritmi ponašaju u prisustvu ovakvih efekata i da li moderniji pristupi, poput FlowSOM algoritma, mogu pružiti stabilnija i bolja rešenja.

2. Opis zadatka

Kao što smo kratko naveli u uvodu, naš zadatak kod ovog projekta se sastoji iz primene i upoređivanja različitih algoritama klasterovanja nad realnim skupom podataka, sa fokusom na poređenje FlowSOM algoritma i standardno korišćenih algoritama nenadgledanog učenja (KMeans, GMM, DBSCAN, HDBSCAN).

Osnovni cilj zadatka jeste da se ispita kako izbor algoritma klasterovanja utiče na kvalitet grupisanja podataka, naročito u slučaju visokodimenzionalnih realnih senzorskih podataka kod kojih su prisutni šum, korelacije između atributa i fenomen drifta. Takođe (U okviru ove dokumentacije) posvećena je i posebna pažnja za razumevanje razlika između klasičnih algoritama klasterovanja i savremenijeg pristupa zasnovanog na samoorganizujućim mapama.

U okviru rada bilo je neophodno realizovati sledeće korake:

1. Analiza i razumevanje skupa podataka

Prvi korak podrazumevao je upoznavanje sa strukturom i karakteristikama izabranog skupa podataka.

2. Pretprocesiranje podataka

Pre primene algoritama klasterovanja bilo je obavezno sprovesti odgovarajuće tehnike pretprocesiranja.

3. Vizuelizacija podataka

Radi boljeg razumevanja podataka, izvršena je osnovna vizuelizacija.

4. Redukcija podataka

U skladu sa zahtevom opšte strukture projekta, sprovedene su 2 metode redukcije (FS i PCA) kako bi se performanse algoritama uporedile i na različitim verzijama skupa podataka a ne samo na potpunom.

5. Primena algoritama klasterovanja

Ključan deo projekta bila je primena minimum pet različitih algoritama klasterovanja. Algoritmi su primenjeni nad kompletnim pretprocesiranim skupom podataka i 2 redukovana skupa, kako bi se ispitaio uticaj izbora atributa na krajnje rezultate i performanse algoritama. Primenjeni su algoritmi zasnovani na nenadgledanom učenju koji su standardno korišćeni u praksi i FlowSOM algoritam kao moderniji pristup klasterovanju.

6. Evaluacija algoritama

Nakon primene algoritama, iskorišćene su različite metrike za evaluaciju dobijenih modela.

7. Analiza i poređenje rezultata

Nakon primene i evaluacije algoritama, izvršena je detaljna analiza rezultata koja je obuhvatila poređenje strukture klastera dobijenih različitim algoritmima kao i upoređivanje performansi na osnovu gore navedenih metrika.

3. Podaci

3.1. Izvor i kontekst

U ovom radu korišćen je skup podataka gas-drift-different-concentrations, koji je javno dostupan na OpenML platformi pod identifikatorom 1477. Skup podataka potiče iz oblasti analize gasnih senzora i razvijen je u okviru istraživanja problema drifta senzora, odnosno promene karakteristika senzorskih odgovora tokom vremena.

Cilj originalnog eksperimenta bio je razlikovanje više vrsta gasova pri različitim koncentracijama, uz istovremeno praćenje degradacije i promene ponašanja senzora kroz duži vremenski period. Ovaj skup podataka je posebno pogodan za zadatke klasterovanja jer sadrži visokodimenzionalne numeričke podatke, izražen šum, jake korelacije između atributa i prisutan konceptualni drift, što predstavlja realističan i izazovan scenario za primenu algoritama nenadgledanog učenja.

3.2. Struktura

Skup podataka sadrži:

- 13 910 instanci
- 131 atribut od čega:
 - 1 identifikacioni atribut (id)
 - 128 numeričkih atributa koji predstavljaju karakteristike odziva senzora
 - 1 atribut koji opisuje koncentraciju gasa (V129)
 - 1 ciljni atribut (Class) koji označava tip gasa

Svaka instanca u skupu podataka predstavlja jedno merenje odgovora senzorskog sistema na prisustvo određenog gasa pri konkretnoj koncentraciji. Sve vrednosti atributa su numeričke, osim ciljnog atributa koji je kodiran celobrojnim oznakama klasa.

3.3. Opis atributa

Glavni deo u analizi skupa podataka čine atributi označeni nazivima V1–V128, koji predstavljaju karakteristike signala sa gasnih senzora. Sistem se sastoji od 16 individualnih senzora, a za svaki senzor izračunato je 8 različitih karakteristika, čime se dobija ukupno 128 atributa.

Karakteristike senzora obuhvataju:

- Statičke karakteristike, koje opisuju intenzitet promene električnog otpora senzora u prisustvu gasa
- Dinamičke karakteristike, koje opisuju način na koji se signal menja tokom vremena, odnosno brzinu rasta i opadanja senzorskog odziva

Zbog ovakve konstrukcije atributa, vidljiva je značajna međusobna korelisanost pojedinih karakteristika, kako unutar istog senzora, tako i između različitih senzora, što dodatno komplikuje proces klasterovanja.

3.4. Atribut koncentracije gasa


Pored senzorskih karakteristika, skup podataka sadrži i atribut V129, koji opisuje koncentraciju gasa izraženu numeričkom vrednošću. Koncentracija varira u širokom opsegu (npr. 10, 50, 150, 250, 600), što omogućava analizu uticaja jačine prisustva gasa na odziv senzora.

Ovaj atribut nije korišćen kao ulaz algoritama klasterovanja, jer predstavlja eksperimentalni uslov merenja, a ne senzorski odziv. Njegovo uključivanje moglo bi dovesti do grupisanja instanci prema nivou koncentracije, što nije u skladu sa ciljem analize. Ipak, atribut je zadržan radi interpretacije rezultata.

3.5. Ciljni atribut Class

Ciljni atribut Class omogućava poređenje dobijenih klastera sa stvarnim klasama gasova i pruža dodatni uvid u to u kojoj meri klasteri odgovaraju realnoj semantici podataka.

Na ovaj način bilo je moguće izvršiti procenu kvaliteta klasterovanja primenom odgovarajućih evaluacionih mera, kao što su ARI (prilagođeni Randov indeks) i NMI (normalizovana međusobna informacija). Ove mere korišćene su isključivo u fazi analize rezultata, dok algoritmi klasterovanja nisu koristili ciljnu kolonu.



4. Pretprocesiranje

4.1. Učitavanje i inicijalno čišćenje podataka

Skup podataka je preuzet sa linka navedenog u prijavi rada u ARFF formatu, konvertovan je u csv format korišćenjem online konvertera a zatim smešten u data/raw direktorijum i učitao korišćenjem biblioteke pandas.

Prvi korak pretprocesiranja podrazumevao je uklanjanje atributa koji ne nose informaciju relevantnu za proces klasterovanja, konkretno „ID“, „Class“ i „V129“ atributa. Identifikaciona kolona id je uklonjena jer ne sadrži semantičku informaciju o senzorskim merenjima i služi isključivo za identifikaciju instanci. Razlog izostavljanja preostala 2 navedena atributa je već naveden u prethodnom poglavlju.

Na kraju zadržani su isključivo numerički atributi koji predstavljaju senzorske karakteristike (V1–V128).

```
[33]: # Ucitavanje podataka
import os
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import RobustScaler
from sklearn.decomposition import PCA

rawData = "../../data/raw/dataset.csv"
processedDir = "../../data/processed"

outPath = os.path.join(processedDir, "ProcessedData.csv")

df = pd.read_csv(rawData)
df.shape
```

```
[33]: (13910, 131)
```

```
[34]: # Inicijalno sredjivanje (Izbacivanje neNumerickih kolona i bespotrebnih kolona)
df = df.drop(columns=["id"])

y1 = df["Class"]
y2 = df["V129"]
X = df.drop(columns=["Class"])
X = X.drop(columns=["V129"])

X = X.select_dtypes(include=[np.number])
X.shape
```

```
[34]: (13910, 128)
```

4.2. Analiza nedostajućih vrednosti

Naredni korak bila je analiza nedostajućih vrednosti. Utvrđeno je da skup podataka ne sadrži nedostajuće vrednosti, pa nije bilo potrebe za primenom tehnika imputacije.

Ova analiza je obavezna jer prisustvo nedostajućih vrednosti može negativno uticati na performanse algoritama klasterovanja i na evaluacione metrike.

```
# NaN analiza
nan = X.isna().sum().sum()
nan
0
```

4.3. Obrada Outliera (Ekstremnih vrednosti)

Realni senzorski podaci često sadrže ekstremne vrednosti usled šuma, mernih grešaka ili degradacije senzora tokom vremena.

Da bi se smanjio uticaj ovakvih vrednosti, primenjena je tehnika odsecanja kvantilima. Za svaki atribut definisane su donja i gornja granica na 1% i 99% kvantilu, nakon čega su vrednosti van ovog opsega ograničene na granične vrednosti i dobijeno je da je odsečeno 35840 instanci. Ovim pristupom zadržana je struktura podataka, dok je smanjen uticaj ekstremnih merenja koja bi mogla značajno iskriviti rezultate klasterovanja.

```
[45]: # Rad sa outlierima
      LQ = 0.01
      RQ = 0.99

      clippedX = X.copy()

      brojOdsecenih = 0

      for col in clippedX.columns:
          leftQ = clippedX[col].quantile(LQ)
          rightQ = clippedX[col].quantile(RQ)

          original = clippedX[col]

          nL = (original < leftQ).sum()
          nR = (original > rightQ).sum()
          brojOdsecenih += nL + nR

          clippedX[col] = original.clip(leftQ, rightQ)

      brojOdsecenih

[45]: 35840
```

4.4. Skaliranje

S obzirom na to da senzorski atributi imaju različite opsege vrednosti, izvršena je standardizacija korišćenjem RobustScaler metode. RobustScaler je izabran jer je otporniji na prisustvo outliera u poređenju sa standardnim Z-score skaliranjem.

Skaliranje je sprovedeno korišćenjem interkvantilnog opsega (5–95 percentil), čime su svi atributi transformisani na uporedivu skalu, što je ključno za algoritme zasnovane na udaljenostima, kao što su KMeans, DBSCAN i GMM.

```
# Standardizacija
scaler = RobustScaler(quantile_range=(5, 95))
scaledX = scaler.fit_transform(clippedX)
```

4.5. Formiranje pretprocesiranog skupa podataka

Nakon primene prethodnih koraka, formiran je finalni pretprocesirani skup podataka koji sadrži skalirane senzorske attribute. Ciljna kolona Class je dodata u posebnu kolonu radi kasnije evaluacije klastera, ali nije korišćena tokom treniranja modela.

Dobijeni pretprocesirani skup podataka sačuvan je u posebnom fajlu i predstavlja osnovu za dalje faze analize, uključujući redukciju dimenzionalnosti i primenu algoritama klasterovanja.

```
# Cuvanje pretprocesiranog skupa
processedData = pd.DataFrame(
    scaledX,
    columns=X.columns
)

if y1 is not None:
    processedData["Class"] = y1.values

if y2 is not None:
    processedData["V129"] = y2.values

processedData.to_csv(outPath, index=False)
processedData.shape

(13910, 130)
```

5. Redukcija (PCA, Feature Selection)

U skladu sa zvaničnim zahtevima u vezi opšte strukture projekta ali i s obzirom na visok broj atributa i njihovu međusobnu nezanemarljivu korelaciju korišćene su metode redukcije dimenzionalnosti primenjene nad originalnim punim pretprocesiranim skupom podataka kako bi se poboljšale performanse algoritama klasterovanja i olakšala interpretacija rezultata.

U radu su primenjene dve različite metode redukcije:

- Redukcija zasnovana na selekciji atributa (Feature Selection)
- Redukcija zasnovana na transformaciji prostora atributa (PCA)

Na ovaj način omogućeno je poređenje algoritama klasterovanja na tri verzije skupa podataka: punom pretprocesiranim, FS redukovanom i PCA redukovanom skupu.

5.1. Feature Selection

Feature Selection predstavlja proces odabira podskupa originalnih atributa koji nose najviše informacija relevantnih za dalju analizu. Za razliku od PCA metode, Feature Selection zadržava originalnu semantiku atributa, što olakšava interpretaciju rezultata.

U narednom delu, objašnjeni su koraci implementacije FS redukcije u vidu podpoglavlja

5.1.1. Eliminacija atributa sa malom varijansom

Prvi korak FS metode bila je eliminacija atributa sa veoma malom varijansom. Atributi sa malom varijansom nose malo informacija jer se njihove vrednosti gotovo ne menjaju između instanci.

U ovom radu korišćen je algoritam Variance Threshold sa pragom od 0.01

```
vt = VarianceThreshold(threshold=0.01)
varX = vt.fit_transform(X)
```

5.1.2. Eliminacija visoko korelisanih atributa

S obzirom na to da su senzorske karakteristike snažno korelisane, dodatno je izvršena eliminacija redundantnih atributa.

Izračunata je korelaciona matrica, a atributi sa koeficijentom korelacije većim od 0.95 uklonjeni su iz skupa. Ovim pristupom smanjen je broj atributa uz očuvanje informativnosti skupa podataka.


```
corrMatrix = varData.corr().abs()
upper = corrMatrix.where(np.triu(np.ones(corrMatrix.shape), k=1).astype(bool))

corrThreshold = 0.95
drop = [col for col in upper.columns if any(upper[col] > corrThreshold)]

fsData = varData.drop(columns=drop)
```

5.1.3. Vizuelizacija korelacije nakon primene FS

Na slici ispod prikazana je korelaciona matrica atributa nakon primene Feature Selection metode. Može se uočiti značajno smanjenje korelacije između atributa u odnosu na korelaciju u punom skupu, što potvrđuje uspešnost eliminacije redundantnih karakteristika.



5.2. PCA

Principal Component Analysis predstavlja linearnu transformacionu metodu koja originalni visokodimenzionalni prostor projektuje u novi prostor manjih dimenzija, pri čemu se maksimalno očuvava varijansa podataka.

Za razliku od Feature Selection metode, PCA ne zadržava originalne attribute, već formira nove ortogonalne komponente koje predstavljaju linearne kombinacije originalnih atributa.

U narednom delu, objašnjeni su koraci implementacije PCA redukcije u vidu podpoglavlja

5.2.1. Izbor broja komponenti na osnovu objašnjene varijanse

Radi ne nasumičnog izbora broja PCA komponenti, prvi korak koji je primenjen u radu je automatski izbor broja PCA komponenti na osnovu kumulativne objašnjene varijanse (explained variance).

Objašnjena varijansa predstavlja procenat ukupne varijanse podataka koji je objašnjen datom komponentom, dok kumulativna objašnjena varijansa predstavlja sumu varijansi prvih k komponenti.

Broj komponenti izabran je tako da kumulativna objašnjena varijansa bude najmanje 95% (Razlog iza izbora baš ovog broja kako u PCA tako i u FS, biće objašnjen na kraju ovog poglavlja).

```
# Explained Variance
explained = pcaFull.explained_variance_ratio_
cumExplained = np.cumsum(explained)

nComp = np.argmax(cumExplained >= 0.95) + 1
```


5.2.2. Transformacija podataka u PCA prostor

Nakon izbora broja komponenti, izvršena je projekcija podataka u PCA prostor. Rezultat je novi skup atributa označen kao PC1, PC2, ..., PCn, koji predstavljaju glavne PCA komponente.

```
pca = PCA(n_components=nComp, random_state=42)
pcaX = pca.fit_transform(X)
```

5.2.3. Vizuelizacija PCA objašnjene varijanse

Na slici ispod prikazana je kumulativna objašnjena varijansa u zavisnosti od broja komponenti. Može se uočiti da relativno mali broj komponenti objašnjava veliki deo varijanse, što potvrđuje postojanje značajne redundancije u originalnom skupu atributa.



5.3. Poređenje FS i PCA metoda

Feature Selection i PCA predstavljaju dva potpuno različita pristupa redukcije dimenzionalnosti.

Feature Selection zadržava originalne attribute, čime se omogućava interpretacija senzorskih karakteristika i njihovog uticaja na klasterovanje.

Sa druge strane, PCA transformiše podatke u novi prostor, što često dovodi do boljih performansi algoritama klasterovanja, ali uz gubitak direktne interpretabilnosti atributa.

U ovom radu oba pristupa su korišćena kako bi se analiziralo kako izbor redukcije utiče na performanse različitih algoritama klasterovanja.

Jako bitna stvar za koju je ranije rečeno da će biti objašnjena na kraju poglavlja je izbor praga od 95% kumulativne objašnjene varijanse i korelacionog praga od 0.95. Razlog za odabir baš ovog broja je u kompromisu između smanjenja dimenzionalnosti i očuvanja informacija, što je u glavnom u skladu sa preporukama iz literature vezane za analizu visokodimenzijskih podataka.

6. Algoritmi Klasterovanja

U ovom poglavlju opisani su algoritmi klasterovanja koji su primenjeni nad tri verzije skupa podataka: potpunim pretprocesiranim skupom, Feature Selection redukovanim skupom i PCA redukovanim skupom.

Cilj primene ovih 5 različitih algoritama jeste poređenje klasičnih metoda nenadgledanog učenja sa modernijim pristupom zasnovanim na samoorganizujućim mapama tj. FlowSOM algoritmom, kao i analiza njihovog ponašanja u prisustvu visokodimenzionalnih senzorskih podataka sa šumom i driftom.

Za sve algoritme korišćene su iste metrike za evaluaciju: Silhouette indeks, Davies–Bouldin indeks, ARI (Adjusted Rand Index) i NMI (Normalized Mutual Information).

Vizuelizacija klastera izvršena je korišćenjem UMAP i t-SNE metoda radi boljeg razumevanja strukture podataka.

Atribut koncentracije gasa (V129) i ciljni atribut klase (Class) nisu korišćeni kao ulaz algoritama.

6.1. KMeans

6.1.1. Opis algoritma

KMeans je jedan od najpoznatijih i najčešće korišćenih algoritama za particiono klasterovanje. Cilj algoritma je podela skupa instanci na unapred definisan broj klastera k , tako da se minimizuje suma kvadratnih rastojanja između instanci i centra klastera kojem pripadaju.

Algoritam iterativno izvršava sledeće korake:

1. Inicijalizacija k centara klastera
2. Dodela svake instance najbližem centru (najčešće po Euklidskom rastojanju)
3. Ponovno izračunavanje centara kao srednje vrednosti instanci u klasteru
4. Ponavljanje postupka dok se ne dođe do konvergencije

KMeans pretpostavlja sferne klastere približno jednake veličine i osetljiv je na šum i outliere (ekstremne vrednosti).

6.1.2. Izbor broja klastera

Pošto K-means zahteva unapred definisan broj klastera, primenjena je Elbow metoda, zarad izbegavanja hardkodovanja i nasumičnog odabira k.

Za vrednosti k u opsegu od 2 do 15 izračunata je inercija (suma kvadratnih odstupanja od centara). Kao optimalna vrednost k izabrana je ona kod koje dolazi do najveće promene druge razlike inercije, što predstavlja automatizovanu verziju Elbow kriterijuma.

6.1.3. Implementacija

Implementacija je realizovana korišćenjem biblioteke scikit-learn. Koraci koje smo izvršili u implementaciji su sledeći:

1. Učitavanje odgovarajuće verzije skupa podataka
2. Uklanjanje atributa Class i V129
3. Određivanje optimalnog broja klastera Elbow metodom
4. Treniranje KMeans modela sa izabranim k
5. Dodela klusterskih oznaka svim instancama
6. Evaluacija rezultata pomoću Silhouette i Davies–Bouldin indeksa
7. Poređenje sa stvarnim klasama pomoću ARI i NMI
8. Vizuelizacija klastera u 2D prostoru primenom UMAP i t-SNE metoda

6.2. GMM – Gaussian Mixture Model

6.2.1. Opis algoritma

Gaussian Mixture Model predstavlja probabilistički model koji pretpostavlja da su podaci generisani kao mešavina više multivarijantnih normalnih raspodela. Svaki klaster je opisan sopstvenom srednjom vrednošću i kovarijacionom matricom, čime se omogućava modelovanje eliptičnih klastera različitih oblika i orijentacija.

Za razliku od KMeans algoritma, GMM omogućava meku pripadnost instanci klasterima, tj. svakoj instanci se dodeljuje verovatnoća pripadnosti svakom klasteru.

6.2.2. Određivanje broja komponenti

Optimalan broj komponenti određen je pomoću Bayesian Information Criterion (BIC). Modeli su trenirani za broj komponenti u opsegu od 2 do 10, a kao optimalan je izabran onaj sa najmanjom BIC vrednošću.

Ovakav pristup omogućava balansiranje između kvaliteta prilagođavanja modela i njegove složenosti.

6.2.3. Implementacija

Implementacija GMM algoritma izvršena je u sledećim koracima:

1. Učitavanje i priprema podataka
2. Uklanjanje neodgovarajućih atributa
3. Treniranje GMM modela za različit broj komponenti
4. Izbor optimalnog modela na osnovu BIC kriterijuma
5. Dodela klusterskih oznaka instancama
6. Izračunavanje metrika za evaluaciju
7. Vizuelizacija rezultata primenom UMAP i t-SNE projekcija

6.3. DBSCAN

6.3.1. Opis algoritma

DBSCAN je algoritam klasterovanja zasnovan na gustini podataka, čija je osnovna ideja da se klasteri formiraju kao oblasti visoke gustine instanci u prostoru atributa, dok se instance koje se nalaze u oblastima niske gustine označavaju kao šum (noise).

Za razliku od particionih metoda, DBSCAN ne zahteva unapred definisan broj klastera i sposoban je da identifikuje klasterne proizvoljnog oblika. Algoritam ne zahteva unapred definisan broj klastera, ali zahteva izbor dva parametra:

- `eps` – maksimalno rastojanje između instanci u istom susedstvu
- `min_samples` – minimalan broj instanci potreban za formiranje gustog regiona

Na osnovu ovih parametara, instance se klasifikuju kao:

- Jezgrene tačke
- Granične tačke
- Šum

Klaster se formira širenjem od jezgrenih tačaka ka njihovim gustim susedstvima.

6.3.2. Izbor parametara i implementacija

DBSCAN je implementiran korišćenjem biblioteke `scikit-learn`. Algoritam je primenjen nad sve tri varijante skupa podataka (full, PCA, FS).

Izbor parametara izvršen je primenom grid pretrage, pri čemu su razmatrane različite kombinacije parametara `eps` i `min_samples`.

Za svaku kombinaciju:

1. Izvršeno je klasterovanje
2. Eliminirana su trivijalna rešenja sa premalim brojem klastera
3. Izračunat je Silhouette indeks nad instancama koje nisu označene kao šum
4. Izabrana je kombinacija parametara koja maksimizuje Silhouette indeks

Nakon izbora optimalnih parametara, izvršena je:

- Analiza broja klastera
- Procena odnosa šuma u skupu podataka
- Evaluacija pomoću Davies–Bouldin indeksa
- Poređenje sa stvarnim klasama pomoću ARI i NMI

Rezultati su vizuelizovani primenom UMAP i t-SNE projekcija, pri čemu su instance označene kao šum jasno izdvojene.

6.4. HDBSCAN

6.4.1. Opis algoritma

HDBSCAN predstavlja hijerarhijsku ekstenziju DBSCAN algoritma, dizajniranu da prevaziđe problem izbora fiksnog parametra ϵ . Umesto jedne vrednosti gustine, HDBSCAN analizira strukturu podataka kroz više nivoa gustine i identifikuje klastere koji su stabilni kroz širok opseg parametara.

Algoritam gradi hijerarhijsko stablo klastera na osnovu minimalnog rastojanja između instanci, a zatim primenjuje kriterijum stabilnosti kako bi izdvojio najznačajnije klastere. Instance koje ne pripadaju nijednom stabilnom klasteru označavaju se kao šum.

6.4.2. Prednosti

U poređenju sa DBSCAN algoritmom, HDBSCAN:

- Se bolje nosi sa promenljivom gustinom podataka
- Je robusniji na šum i outliere
- Zahteva manji broj hiperparametara

Ove karakteristike ga čine pogodnijim za realne, nestrukturisane skupove podataka, kao što je naš skup sa gasnim senzorima.

6.4.3. Implementacija i parametri

HDBSCAN je implementiran korišćenjem biblioteke hdbscan. Razmatrani su parametri:

- `min_cluster_size`
- `min_samples`

Za svaku kombinaciju parametara:

1. Izvršeno je klasterovanje
2. Provereno je postojanje najmanje dva klastera
3. Izračunat je Silhouette indeks nad instancama koje nisu šum
4. Izabrana je kombinacija parametara sa najboljim Silhouette rezultatom

Pored standardnih metrika, analiziran je i:

- Broj formiranih klastera
- Procenat instanci označenih kao šum

Rezultati su vizuelizovani pomoću UMAP i t-SNE metoda, pri čemu je šum jasno istaknut.

6.5. FlowSOM

6.5.1. Opis algoritma

FlowSOM je algoritam zasnovan na samoorganizujućim mapama (Self-Organizing Maps – SOM), koji kombinuje neuronske mreže sa klasičnim klasterovanjem. Originalno je razvijen za analizu protočne citometrije i rad sa CyTOF podacima (Koji nisu u ovom radu korišćeni iz razloga što su to većinski skupovi podataka sa do 40 atributa, dok je jedan od glavnih zahteva ovog rada korišćenje skupa podataka sa više od 100 atributa), ali se pokazao izuzetno efikasnim i za obradu velikih, visokodimenzionalnih skupova podataka.

Za razliku od klasičnih algoritama, FlowSOM ne klasteruje direktno instance, već:

1. Uči topološku reprezentaciju podataka u obliku mreže čvorova
2. Mapira svaku instancu na najbliži čvor
3. Vrš klasterovanje čvorova u meta-klaster

Ovaj pristup omogućava značajno smanjenje složenosti problema.

6.5.2. Uloga FlowSOM algoritma

FlowSOM predstavlja centralni algoritam ovog rada i služi kao referentna tačka za poređenje sa klasičnim metodama klasterovanja. Njegova sposobnost da sažme kompleksnu strukturu podataka u manji broj reprezentativnih jedinica čini ga posebno pogodnim za analizu senzorskih podataka sa izraženim driftom i korelacijom atributa.

6.5.3. Implementacija i izbor parametara

Implementacija FlowSOM algoritma realizovana je korišćenjem programskog jezika R i biblioteke FlowSOM, koja predstavlja standardni (A i originalno razvijeni) alat za primenu ovog algoritma. Algoritam je primenjen nad sve tri varijante skupa podataka.

Pre same primene algoritma, izvršena je priprema podataka koja obuhvata uklanjanje ciljnog atributa klase i atributa koncentracije gasa, kao i proveru numeričkog tipa svih preostalih atributa. Nedostajuće vrednosti su uklonjene kako bi se obezbedila korektna primena algoritma.

U prvoj fazi FlowSOM algoritma trenirana je samoorganizujuća mapa (SOM). Kao struktura mreže izabrana je pravougaona mapa dimenzija 10×10 , što predstavlja kompromis između dovoljno fine reprezentacije prostora podataka i ograničenja složenosti modela. Ovakav izbor omogućava da se kompleksna struktura visokodimenzionalnih podataka sažme u 100 reprezentativnih čvorova. Tokom treniranja, ulazni podaci su standardizovani kako bi se sprečio dominantan uticaj pojedinih atributa.

Nakon treniranja SOM mreže, svaka instanca iz skupa podataka mapirana je na najbliži čvor mreže, čime je obezbeđeno značajno smanjenje broja objekata nad kojima se vrši dalja analiza. U sledećem koraku izvršeno je klasterovanje SOM čvorova u meta-klastere primenom KMeans algoritma.

Broj meta-klastera nije unapred definisan, već je određen automatski. Razmatran je opseg od 2 do 15 meta-klastera, a za svaku vrednost izvršeno je klasterovanje SOM čvorova i preslikavanje dobijenih meta-klasterskih oznaka na originalne instance. Kao kriterijum za izbor optimalnog broja meta-klastera korišćen je Silhouette indeks, izračunat nad nasumično odabranim podskupom instanci kako bi se smanjili računski zahtevi.

Nakon određivanja optimalnog broja meta-klastera, izvršena je dodela konačnih klasterskih oznaka svim instancama u skupu podataka. Dobijeni rezultati evaluirani su pomoću unutrašnjih metrika kvaliteta klasterovanja, kao što su Silhouette i Davies–Bouldin indeks, kao i spoljašnjih metrika (ARI i NMI) u odnosu na poznate klase gasova.

Radi dodatne interpretacije rezultata, klasterske strukture su vizuelizovane primenom UMAP i t-SNE projekcija.

7. Analiza dobijenih rezultata

7.1. KMeans

7.1.1. Numeričke metrike evaluacije


Za evaluaciju kvaliteta klasterovanja korišćene su interne i eksterne metrike: Silhouette koeficijent, Davies–Bouldin indeks, Adjusted Rand Index (ARI) i Normalized Mutual Information (NMI). Rezultati su prikazani u Tabeli ispod:

	Dataset	Algorithm	K	Silhouette	Davies_Bouldin	ARI	NMI
1	full	KMeans	4	0.37953136971903756	1.251743935937907	0.09915934042321772	0.22559043546449142
2	pca	KMeans	4	0.3990060170508575	1.1855373253143808		
3	fs	KMeans	4	0.3707697388241109	1.1638732420397855		

Silhouette koeficijent je u svim slučajevima oko (0.37–0.40), što ukazuje na umereno dobro razdvajanje klastera. Davies–Bouldin indeks je relativno nizak (1.16–1.25), što sugeriše zadovoljavajuću homogenost unutar klastera i separaciju između klastera.

Eksterne metrike (ARI i NMI) su izračunate samo za pun pretprocesirani skup podataka jer jedino on sadrži prave klase. Vrednosti $ARI = 0.099$ i $NMI = 0.226$ ukazuju na slabo poklapanje između dobijenih klastera i stvarnih klasa, što je očekivano jer je KMeans algoritam potpuno nenadgledan i optimizuje samo unutrašnju strukturu podataka.

7.1.2. tSNE/UMAP vizuelizacije



7.1.3. Analiza klastera

Distribucija instanci po klasterima za sva tri skupa podataka pokazuje izraženu neravnotežu. Ova raspodela pokazuje da K-Means identifikuje jedan dominantni klaster i nekoliko manjih specifičnih podgrupa, što je tipično za visoko-dimenzionalne realne podatke.

Profil klastera je analiziran korišćenjem srednjih vrednosti standardizovanih atributa po klasteru. Potvrđeno je da PCA projekcija uspešno razdvaja latentne strukture koje K-Means dalje grupiše.

7.1.4. Rezime

K-Means algoritam je pokazao stabilno ponašanje na svim verzijama skupa podataka, pri čemu je optimalan broj klastera izabran kao $K=4$ pomoću Elbow metode.

Algoritam je uspeo da identifikuje jasno dominantni klaster i nekoliko manjih, specifičnih grupa, što je u skladu sa očekivanjima za realne visokodimenzijske podatke.

Interne metrike (Silhouette i Davies–Bouldin) ukazuju na umeren kvalitet klasterovanja, dok su eksterne metrike pokazale slabo poklapanje sa stvarnim klasama. To potvrđuje da K-Means grupiše podatke prema statističkoj strukturi, a ne nužno prema semantičkim klasama.

Rezultati na PCA i FS skupovima su slični originalnom skupu, što sugerira da redukcija dimenzionalnosti nije značajno narušila strukturu podataka, već je čak blago poboljšala homogenost klastera.

7.2. GMM

7.2.1. Numeričke metrike evaluacije

Za evaluaciju kvaliteta klasterovanja Gaussian Mixture Model (GMM) algoritma korišćene su interne i eksterne metrike: Silhouette koeficijent, Davies–Bouldin indeks, Adjusted Rand Index (ARI) i Normalized Mutual Information (NMI). Rezultati su prikazani u tabeli ispod:

	Dataset	Algorithm	BestComponents	Silhouette	Davies_Bouldin	ARI	NMI
1	full	GMM	9	0.0957141507118714	1.6738059930043148	0.2112812875317095	0.36591288567948954
2	pca	GMM	10	0.011953666743554551	2.612316356971753		
3	fs	GMM	9	0.00651849035521451	2.30534703097132		


Silhouette koeficijent za puni skup podataka iznosi 0.096, što ukazuje na veoma slabo razdvajanje klastera u originalnom prostoru atributa. Za PCA i FS verzije skupa podataka vrednosti Silhouette koeficijenta su još niže (0.012

i 0.007), što sugerije da redukcija dimenzionalnosti nije poboljšala separabilnost klastera za GMM algoritam.

Davies–Bouldin indeks za puni skup podataka iznosi 1.67, dok su za PCA i FS verzije vrednosti 2.61 i 2.31. Više vrednosti ovog indeksa ukazuju na lošiju separaciju klastera i veće preklapanje distribucija, što potvrđuje da GMM nije uspeo da pronađe jasno odvojene klaster strukture u ovom skupu podataka.

Eksterne metrike (ARI i NMI) su izračunate samo za puni skup podataka jer jedino on sadrži prave klase. Vrednosti $ARI = 0.211$ i $NMI = 0.366$ ukazuju na umereno, ali i dalje ograničeno poklapanje između dobijenih klastera i stvarnih klasa. Ovo je očekivano jer GMM modeluje podatke kao kombinaciju Gaussovih distribucija i optimizuje verovatnoću podataka, a ne direktno semantičku klasifikaciju.

7.2.2. tSNE/UMAP vizuelizacije



7.2.3. Analiza klastera

Distribucija instanci po klasterima za puni i FS skup podataka pokazuje izraženu neravnotežu između klastera. Na primer, u punom skupu podataka jedan klaster sadrži preko 2600 instanci, dok pojedini klasteri imaju znatno manje elemenata. Sličan obrazac uočen je i u FS verziji skupa podataka, gde dominantni klasteri koegzistiraju sa manjim specifičnim grupama.

Profil klastera analiziran je korišćenjem srednjih vrednosti standardizovanih atributa po klasteru. Rezultati ukazuju da pojedini klasteri imaju ekstremne vrednosti određenih atributa, što sugeriše da GMM identifikuje latentne

podgrupe sa specifičnim statističkim karakteristikama. Međutim, značajna varijabilnost unutar klastera ukazuje na to da klasteri nisu homogeni i da se distribucije snažno preklapaju.

Posebno je uočeno da neki klasteri imaju visoko pozitivne ili negativne vrednosti standardizovanih atributa, što može ukazivati na specifične obrasce ponašanja ili anomalije u podacima. Ovo sugerise da GMM može biti koristan za identifikaciju latentnih statističkih profila, ali ne i za jasno klasterovanje u ovom slučaju.

7.2.4. Rezime

GMM algoritam je pokazao slabije performanse u odnosu na KMeans algoritam na ovom skupu podataka. Optimalan broj komponenti izabran je kao 9 ili 10 u zavisnosti od verzije skupa podataka, što ukazuje na kompleksnu latentnu strukturu podataka.

Interne metrike (Silhouette i Davies–Bouldin) ukazuju na loš kvalitet klasterovanja i značajno preklapanje klastera, dok eksterne metrike pokazuju umereno poklapanje sa stvarnim klasama samo za puni skup podataka. Ovo potvrđuje da GMM modeluje statističke distribucije podataka, ali ne uspeva da pronađe jasno razdvojene klastere u visokodimenzionalnom prostoru ovog problema.

Rezultati na PCA i FS skupovima su lošiji nego na originalnom skupu podataka, što sugerise da redukcija dimenzionalnosti uklanja informacije važne za GMM modelovanje distribucija. Ukupno posmatrano, GMM se pokazao manje pogodnim za klasterovanje ovog skupa podataka u poređenju sa KMeans.

7.3. DBSCAN

7.3.1. Numeričke metrike evaluacije

Za evaluaciju DBSCAN algoritma korišćene su interne metrike Silhouette koeficijent i Davies–Bouldin indeks, kao i eksterne metrike Adjusted Rand Index (ARI) i Normalized Mutual Information (NMI) za pun skup podataka.

Rezultati su prikazani u tabeli ispod:


	Dataset	Algorithm	eps	min_samples	Clusters	NoiseRatio	Silhouette	Davies_Bouldin	ARI	NMI
1	full	DBSCAN	1.5	20	6	0.038461538461538464	0.3607703316426858	0.5408436246435371	-0.004592714195061146	0.03924754886786125
2	pca	DBSCAN	1.5	20	5	0.024299065420560748	0.5003357506121694	0.4193859524947278		
3	fs	DBSCAN	1.5	20	3	0.005535585909417685	0.6179804267359976	0.36778743967770394		

Silhouette koeficijent pokazuje značajno poboljšanje u odnosu na KMeans i GMM, posebno na FS i PCA skupovima podataka. Najviša vrednost dobijena je na FS skupu (Silhouette = 0.618), dok je na PCA skupu iznosila 0.500, a na punom skupu 0.361. Ovo ukazuje na dobru separaciju klastera, naročito nakon selekcije karakteristika.

Davies–Bouldin indeks je nizak za sve varijante skupa podataka (0.368–0.541), što sugeriše visoku homogenost unutar klastera i dobru separaciju između klastera.

Eksterne metrike su izračunate samo za pun skup podataka. Dobijene vrednosti ARI = -0.005 i NMI = 0.039 ukazuju na praktično nepostojeće poklapanje između klastera i stvarnih klasa. Negativna vrednost ARI sugeriše da je klasterovanje lošije od slučajne dodele, što je očekivano jer DBSCAN ne optimizuje prema klasama već identifikuje gustinske strukture u podacima.

7.3.2. tSNE/UMAP vizuelizacije



7.3.3. Analiza klastera

Distribucija instanci po klasterima pokazuje izrazitu neravnotežu za sve verzije skupa podataka. Na punom skupu identifikovano je šest klastera i značajan broj tačaka označenih kao šum (535 instanci). Dominantni klaster (0) sadrži većinu instanci (13134), dok su ostali klasteri relativno mali.

Na PCA skupu identifikovano je pet klastera uz manji procenat šuma (338 instanci). Na FS skupu broj klastera se smanjuje na tri, uz veoma mali procenat šuma (77 instanci), što ukazuje da selekcija karakteristika

povećava gustinu struktura i olakšava DBSCAN-u identifikaciju stabilnih klastera.

Profil klastera analiziran je korišćenjem srednjih vrednosti standardizovanih atributa po klasteru.

Na punom skupu podataka, klasteri pokazuju jasno diferencirane obrasce u velikom broju atributa (V1–V128), pri čemu pojedini klasteri imaju ekstremne vrednosti što sugeriše specifične i potencijalno anomalne podgrupe podataka.

Na FS skupu uočene su izrazite razlike između klastera, posebno u atributima V6, V8, V16, V66, V97 i V104, gde klasteri 1 i 3 imaju veoma negativne vrednosti, što ukazuje na ekstremna ponašanja u odnosu na dominantni klaster.

Na PCA skupu klasteri su diferencirani duž glavnih komponenti, posebno PC1, PC2 i PC3, gde se klasteri jasno razdvajaju u latentnom prostoru, što potvrđuje efikasnost redukcije dimenzionalnosti u kombinaciji sa DBSCAN algoritmom.

7.3.4. Rezime

DBSCAN algoritam pokazuje sposobnost identifikacije gustinskih struktura i anomalija, što se vidi kroz detekciju šuma i manjih specifičnih klastera. U poređenju sa KMeans i GMM, DBSCAN je manje sklon formiranju balansiranih klastera i prirodno otkriva neravnomerne i kompleksne strukture podataka.

Najbolji rezultati postignuti su na FS skupu podataka, gde je algoritam identifikovao mali broj kompaktnih klastera sa visokim Silhouette koeficijentom i niskim Davies–Bouldin indeksom, što sugeriše da selekcija karakteristika značajno poboljšava performanse gustinskih metoda klasterovanja.

7.4. HDBSCAN

7.4.1. Numeričke metrike evaluacije

Za evaluaciju kvaliteta klasterovanja korišćene su interne metrike Silhouette koeficijent i Davies–Bouldin indeks, kao i eksterne metrike ARI i NMI za puni skup podataka.

	Dataset	Algorithm	min_cluster_size	min_samples	Clusters	NoiseRatio	Silhouette	Davies_Bouldin	ARI	NMI
1	full	HDBSCAN	5	20	153	0.42300503235082676	0.48950944596943774	0.7144350784921872	0.01927445122850382	0.3827876096740394
2	pca	HDBSCAN	5	20	159	0.4166786484543494	0.5771330454447229	0.608310955354765		
3	fs	HDBSCAN	15	20	97	0.5140905823148814	0.48374862376038913	0.7147422804093968		


Silhouette koeficijent za HDBSCAN je relativno visok, sa vrednostima od 0.49 za puni skup podataka, 0.58 za PCA skup i 0.48 za FS skup, što ukazuje na dobro razdvajanje klastera i jasnu strukturu podataka.

Davies–Bouldin indeks je nizak (0.61–0.71), što sugeriše visoku homogenost unutar klastera i dobru separaciju između njih.

Eksterne metrike su izračunate samo za puni skup podataka. Vrednosti ARI = 0.019 i NMI = 0.383 ukazuju na vrlo slabo poklapanje između dobijenih klastera i stvarnih klasa. Ovo je očekivano jer HDBSCAN, kao potpuno nenadgledan algoritam, identifikuje strukture u podacima koje ne moraju odgovarati semantičkim klasama.

Takođe, primećen je visok procenat šuma (noise) od 41–51%, što ukazuje da algoritam uspešno identifikuje instance koje ne pripadaju nijednoj gustoj strukturi.

7.4.2. tSNE/UMAP vizuelizacije



7.4.3. Analiza klastera

Distribucija instanci po klasterima pokazuje ekstremno veliki broj klastera (97–159), uz dominantnu grupu šuma (cluster -1). Ovo ukazuje da HDBSCAN otkriva fine-grained strukture i mikro-klasterne, što je tipično za algoritme bazirane na gustini.

Profil klastera analiziran je korišćenjem srednjih vrednosti standardizovanih atributa po klasteru. Rezultati pokazuju da pojedini klasteri imaju veoma izražene vrednosti specifičnih atributa, što sugeriše postojanje specifičnih lokalnih obrazaca u podacima.

Klasteri sa pozitivnim standardizovanim vrednostima predstavljaju podgrupe sa pojačanim intenzitetom određenih karakteristika, dok klasteri sa negativnim vrednostima predstavljaju grupe sa smanjenim intenzitetom tih karakteristika.

Veliki broj malih klastera ukazuje na heterogenost podataka i prisustvo lokalnih struktura koje nisu uočljive globalnim metodama poput K-Means ili GMM.

7.4.4. Rezime

HDBSCAN algoritam je identifikovao veliki broj klastera i značajan procenat šuma, što potvrđuje njegovu sposobnost da detektuje kompleksne i lokalne strukture u visoko-dimenzionalnim podacima.

Interne metrike (Silhouette i Davies–Bouldin) ukazuju na visok kvalitet klasterovanja, posebno na PCA i FS skupovima podataka.

Eksterne metrike pokazale su slabo poklapanje sa stvarnim klasama, što potvrđuje da HDBSCAN identifikuje strukture zasnovane na gustini podataka, a ne semantičke klase.

Rezultati sugerišu da je HDBSCAN posebno pogodan za detekciju anomalija i fine-grained obrazaca, ali da generiše veliki broj klastera, što može otežati interpretaciju u praktičnim primenama.

7.5. FlowSOM

7.5.1. Numeričke metrike evaluacije

Za evaluaciju kvaliteta klasterovanja FlowSOM algoritma korišćene su interne metrike Silhouette koeficijent i Davies–Bouldin indeks, kao i eksterne metrike ARI i NMI za puni skup podataka.


	Dataset	Algorithm	SOM_grid	MetaClusters	Silhouette	Davies_Bouldin	ARI	NMI
1	full	FlowSOM	10x10	3	0.414398501255869	1.08236814020256	0.0333631787426692	0.121180328427264
2	pca	FlowSOM	10x10	3	0.431855330032852	1.03163891947949		
3	fs	FlowSOM	10x10	2	0.415468739165789	1.44064553754008		

Silhouette koeficijent za FlowSOM iznosi 0.41 za puni skup podataka, 0.43 za PCA skup i 0.42 za FS skup, što ukazuje na umereno do dobro razdvajanje klastera i stabilnu strukturu u svim verzijama skupa podataka.

Davies–Bouldin indeks je relativno nizak (1.03–1.44), što sugeriše zadovoljavajuću homogenost unutar klastera i dobru separaciju između klastera.

Eksterne metrike su izračunate samo za puni skup podataka. Dobijene vrednosti ARI = 0.033 i NMI = 0.121 ukazuju na veoma slabo poklapanje između dobijenih klastera i stvarnih klasa. Ovo je očekivano jer FlowSOM, kao nenadgledan algoritam, klastere formira na osnovu topološke strukture podataka, a ne prema semantičkim klasama.

7.5.2. tSNE/UMAP vizuelizacije



7.5.3. Analiza klastera

Distribucija instanci po klasterima pokazuje neravnomernu raspodelu. Za puni skup podataka identifikovana su tri meta-klastera, pri čemu jedan klaster sadrži većinu instanci (8948), dok su preostala dva klastera znatno manja (325 i 4637 instanci).

Slična raspodela primećena je i kod PCA skupa podataka, dok FS skup sadrži dva klastera sa izraženom dominacijom prvog klastera.

Ova neravnoteža ukazuje da FlowSOM identifikuje jedan dominantni obrazac u podacima i nekoliko specifičnih podgrupa, što je tipično za realne visokodimenzionalne biomedicinske i tehničke podatke.

Profil klastera analiziran je korišćenjem srednjih vrednosti standardizovanih atributa po klasteru. Rezultati pokazuju da klasteri imaju jasno diferencirane obrasce vrednosti atributa. Neki klasteri imaju pozitivne standardizovane vrednosti za određene attribute, što ukazuje na pojačani intenzitet tih karakteristika, dok drugi klasteri imaju negativne vrednosti, što ukazuje na smanjeni intenzitet istih karakteristika.

Kod PCA projekcije, klasteri su jasno razdvojeni duž glavnih komponenti, što potvrđuje da PCA uspešno hvata latentnu strukturu podataka koju FlowSOM dalje koristi za klasterovanje.

7.5.4. Rezime

FlowSOM algoritam je pokazao stabilno ponašanje na svim verzijama skupa podataka, pri čemu je broj meta-klastera izabran na osnovu interne validacije kao 2 ili 3.

Interne metrike (Silhouette i Davies–Bouldin) ukazuju na umeren do dobar kvalitet klasterovanja, posebno na PCA skupu podataka.

Eksterne metrike (ARI i NMI) pokazale su slabo poklapanje sa stvarnim klasama, što potvrđuje da FlowSOM identifikuje topološke strukture u podacima, a ne nužno semantičke klase.

Rezultati sugerišu da je FlowSOM pogodan za identifikaciju dominantnih obrazaca i topoloških mapa u visokodimenzionalnim podacima, ali da klasteri mogu biti neravnomerno raspoređeni i teže interpretabilni u poređenju sa gustinskim metodama poput HDBSCAN-a.

8. Zaključak

U ovom radu izvršena je detaljna analiza i poređenje pet algoritama klasterovanja – KMeans, Gaussian Mixture Model (GMM), DBSCAN, HDBSCAN i FlowSOM – na realnom visokodimenzionalnom skupu podataka gasnih senzora sa prisutnim šumom, korelacijom atributa i konceptualnim driftom. Algoritmi su primenjeni na tri verzije skupa podataka: punom pretprocesiranom, Feature Selection redukovanom i PCA redukovanom skupu, čime je omogućeno ispitivanje uticaja redukcije dimenzionalnosti na kvalitet klasterovanja.

Pretprocesiranje je obuhvatilo uklanjanje nerelevantnih atributa, obradu ekstremnih vrednosti, skaliranje i formiranje finalnog skupa podataka. Analiza je pokazala da su senzorski atributi snažno korelisani i da postoji značajna redundancija, što je potvrdilo opravdanost primene redukcije dimenzionalnosti. Feature Selection metoda omogućila je zadržavanje interpretabilnih atributa uz smanjenje korelacije, dok je PCA omogućio kompaktnu reprezentaciju podataka uz očuvanje više od 95% varijanse.

Rezultati klasterovanja pokazali su da klasični algoritmi, poput KMeans i GMM, postižu umerene ili slabe performanse u pogledu interne separabilnosti klastera, dok eksterne metrike (ARI i NMI) ukazuju na ograničeno poklapanje klastera sa stvarnim klasama gasova. Ovo potvrđuje da nenadgledani algoritmi prvenstveno grupišu podatke na osnovu statističke strukture, a ne nužno semantičke klasifikacije gasova. GMM je pokazao određenu prednost u poređenju sa KMeans-om u pogledu spoljašnjih metrika, ali je i dalje imao problem sa jasnoćom klusterske strukture.

Algoritmi zasnovani na gustini (DBSCAN i HDBSCAN) pokazali su sposobnost identifikacije šuma i klastera proizvoljnog oblika, što je posebno važno za realne senzorske podatke sa driftom i heterogenom gustinom. HDBSCAN se pokazao robusnijim u odnosu na DBSCAN zbog automatskog određivanja

stabilnih klastera i manjeg oslanjanja na hiperparametre, ali je i dalje identifikovao značajan deo instanci kao šum, što ukazuje na kompleksnost i nelinearnost strukture podataka.

FlowSOM algoritam se istakao kao posebno efikasan pristup za visokodimenzionalne podatke. Korišćenjem samoorganizujućih mapa omogućeno je sažimanje kompleksne strukture podataka u topološku reprezentaciju, nakon čega je izvršeno meta-klasterovanje. FlowSOM je pokazao stabilno ponašanje na sve tri verzije skupa podataka i postigao konkurentne ili bolje interne metrike u poređenju sa klasičnim algoritmima. Njegova sposobnost da očuva topološke odnose između instanci čini ga pogodnim za analizu senzorskih podataka sa konceptualnim driftom.

Analiza uticaja redukcije dimenzionalnosti pokazala je da PCA i Feature Selection u većini slučajeva ne narušavaju strukturu podataka i mogu čak poboljšati homogenost klastera. PCA se pokazao korisnijim za poboljšanje performansi algoritama zasnovanih na udaljenostima, dok je Feature Selection omogućio bolju interpretaciju rezultata kroz originalne senzorske attribute.

Na osnovu dobijenih rezultata može se zaključiti da ne postoji univerzalno najbolji algoritam klasterovanja za ovakve kompleksne senzorske podatke, ali da FlowSOM predstavlja vrlo perspektivan pristup u poređenju sa klasičnim metodama, posebno u visokodimenzionalnim i drift-prisutnim scenarijima. Klasični algoritmi poput KMeans i GMM mogu pružiti osnovni uvid u strukturu podataka, dok algoritmi zasnovani na gustini i neuronskim mapama nude naprednije i robusnije rezultate.

Buduća istraživanja mogla bi uključiti analizu vremenskog aspekta drifta, kao i poređenje FlowSOM algoritma sa drugim savremenim metodama nenadgledanog učenja. Takođe, interesantno bi bilo ispitati polunadgledane i nadgledane pristupe kako bi se dodatno unapredila interpretacija klastera u odnosu na stvarne klase gasova.

9. Literatura

1. Deo implementiranog FlowSOM koda preuzet sa FlowJO stranice
(<https://www.flowjo.com/exchange/plugin/flowsom>)
2. Veb stranica predmeta „Istraživanje podataka 1“ -
<https://matf-istrazivanje-podataka-1.github.io/practices/>
3. Veb stranica predmeta „Istraživanje podataka 2“ -
[https://www.istrazivanjepodataka.matf.bg.ac.rs/IstrazivanjePodataka2.html#3 tab](https://www.istrazivanjepodataka.matf.bg.ac.rs/IstrazivanjePodataka2.html#3%20tab)
4. Scikit learn veb stranica – (<https://scikit-learn.org/stable/modules/clustering.html>)
5. Određeni delovi koda, uglavnom vezani za specifične plotove, preuzeti sa StackOverflow stranice (Primer: <https://stackoverflow.com/questions/57341277/clustering-and-plotting-using-umap>)